Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

Sistema de Inteligencia de Negocios para el Monitoreo de Matrícula en la Educación Superior

Integrante	Código
Daniel Felipe Grisales Corredor	506232081
Giancarlo Guevara Orjuela	507211010
Johan Arturo González Feo	507242006

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	13/11/2026
Repositorio	https://github.com/papagrosly-boop/bi-proyecto-equipo506232081y507211010y507242006
Entorno del modelo	Python 3 en Google Colab (pandas y scikit-learn)

Resumen de la entrega

La pregunta de negocio es qué departamentos tendrán caída de matrícula el próximo año, para que el viceministro de Educación Superior sepa dónde vigilar. El modelo predice, para cada departamento y año, si la matrícula del semestre 1 del año siguiente será menor que la del año actual (clasificación binaria), con 231 registros del data warehouse (33 departamentos, 2015-2021).

Se entrenaron una regresión logística y un bosque aleatorio. Se eligió la regresión logística, que en el conjunto de prueba (2020 y 2021) detectó 7 de las 18 caídas reales (recall de 38,9 %) y no alcanzó el criterio de éxito (recall mínimo de 60 %). Tampoco superó a la regla simple «si cayó este año, caerá el siguiente», que detectó 9 de 18.

Para 2022 el modelo marca 17 de los 33 departamentos con riesgo de caída, que concentran 1.295.313 estudiantes (64,9 % de la matrícula del semestre 1 de 2021). Como solo 2 de cada 10 alarmas fueron ciertas en la prueba, la lista sirve como apoyo para priorizar el seguimiento y no como pronóstico definitivo.

1. Comprensión del negocio

1.1 Pregunta y decisión

La pregunta es la P3 de la tabla 1.3 de la Entrega 1: **¿Qué departamentos tendrán caída de matrícula el próximo año?** Es de tipo BA porque busca predecir un comportamiento futuro a partir de la serie 2015-2021.

La decisión que apoya es del viceministro(a) de Educación Superior del Ministerio de Educación Nacional: con la lista de departamentos en riesgo decide dónde concentrar el seguimiento y las acciones de permanencia y cobertura antes de que la matrícula caiga.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	cae_siguiente: 1 si la matrícula del semestre 1 del año t+1 es menor que la del año t en el departamento; 0 si no
Tipo de problema	Clasificación binaria
Unidad de predicción	Una predicción por departamento y año

1.3 Criterio de éxito

El modelo se considera exitoso si cumple las dos condiciones siguientes en el conjunto de prueba:

1. De cada 10 departamentos que caen, el modelo detecta al menos 6 (recall de la clase «cae» mayor o igual a 60 %).
2. Su exactitud supera la de predecir siempre «no cae».

El criterio se fijó antes de entrenar y no se modificó después de ver los resultados.

2. Comprensión de los datos

2.1 Consulta de extracción

```
-- Extracción del conjunto de datos del modelo (Entrega 3)
-- Una fila por departamento y año, con la matrícula del semestre 1 y sus atributos.
-- Se usa solo el semestre 1 porque la matrícula es semiaditiva: no se suma entre los
-- dos semestres de un año (mismo criterio del tablero de la Entrega 2).
-- Se excluyen los hechos con geografía desconocida (llave -1).
```

```
USE matricula;

SELECT
    t.sk_tiempo                                     AS sk_tiempo,
    t.anio                                          AS anio,
    g.cod_dpto                                      AS cod_dpto,
    g.nom_dpto                                      AS nom_dpto,
    SUM(f.total_matriculados)                       AS matricula_s1,
    SUM(CASE WHEN i.acreditada_alta_calidad = 'SI'
             THEN f.total_matriculados ELSE 0 END) AS matricula_acreditada,
    SUM(CASE WHEN ge.descripcion_genero = 'Femenino'
             THEN f.total_matriculados ELSE 0 END) AS matricula_mujeres,
    COUNT(DISTINCT f.sk_programa)                   AS n_programas,
    COUNT(DISTINCT f.sk_geografia)                  AS n_municipios
FROM fact_matricula f
JOIN dim_tiempo      t  ON t.sk_tiempo      = f.sk_tiempo
JOIN dim_geografia   g  ON g.sk_geografia   = f.sk_geografia
JOIN dim_institucion i  ON i.sk_institucion = f.sk_institucion
JOIN dim_genero      ge ON ge.sk_genero     = f.sk_genero
WHERE t.semestre = 1
  AND f.sk_geografia <> -1
GROUP BY t.sk_tiempo, t.anio, g.cod_dpto, g.nom_dpto
ORDER BY g.cod_dpto, t.anio;
```

La consulta une la tabla de hechos `fact_matricula` con las dimensiones de tiempo, geografía, institución y género, y agrupa la matrícula por departamento y año. Filtra el semestre 1, porque la matrícula es semiaditiva y no se suma entre semestres, y excluye los hechos con geografía desconocida (llave -1). Se tomaron las dimensiones de tiempo, geografía, institución y género; la dimensión de programa solo aporta el conteo de programas desde la tabla de hechos.

2.2 Descripción del conjunto de datos

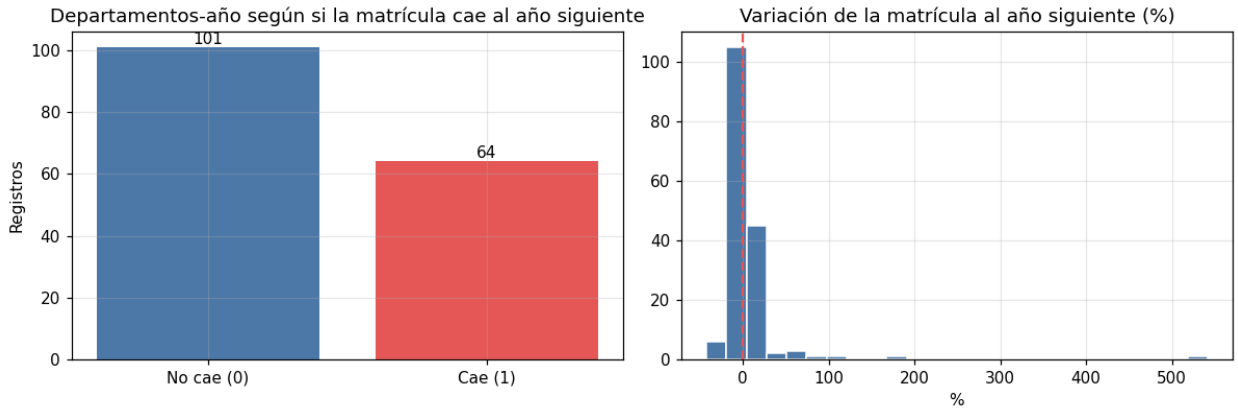
El conjunto tiene **231 registros** (un registro por departamento y año), de **33 departamentos**, con periodo **2015-2021** (semestre 1 de cada año). Todos los departamentos tienen matrícula en los siete años, por lo que ninguno se excluyó. Tras calcular las variaciones y la variable objetivo quedan 165 registros etiquetados (años base 2016-2020) y 33 para predecir 2022 (año base 2021).

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
cod_dpto	Texto	Identificador	dim_geografia.cod_dpto	Código DANE del departamento
nom_dpto	Texto	Identificador	dim_geografia.nom_dpto	Nombre del departamento
anio	Numérica	Identificador	dim_tiempo.anio	Año base t (semestre 1)
matricula_s1	Numérica	Entrada (base de derivadas)	fact_matricula.total_matriculados	Estudiantes matriculados en el semestre 1 del año t
matricula_acreditada	Numérica	Entrada (base de derivadas)	fact_matricula.total_matriculados + dim_institucion.acreditada_alta_calidad	Matriculados en instituciones con acreditación de alta calidad
matricula_mujeres	Numérica	Entrada (base de derivadas)	fact_matricula.total_matriculados + dim_genero.descripcion_genero	Matriculadas de género femenino

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
n_programas	Numérica	Entrada (base de derivadas)	fact_matricula.sk_programa	Programas académicos distintos con matrícula
n_municipios	Numérica	Entrada (base de derivadas)	fact_matricula.sk_geografia	Municipios del departamento con matrícula
cae_siguiente	Binaria (0/1)	Objetivo	fact_matricula.total_matriculados (años t y t+1)	1 si la matrícula del semestre 1 de t+1 es menor que la de t
log_matricula	Numérica	Entrada	Derivada de matricula_s1	Logaritmo natural de la matrícula del año t
var_anual	Numérica	Entrada	Derivada de matricula_s1 (t y t-1)	Variación porcentual frente al año anterior
cayo_anio_actual	Binaria (0/1)	Entrada	Derivada de var_anual	1 si la matrícula ya cayó en el año t
pct_acreditada	Numérica	Entrada	Derivada de matricula_acreditada	Proporción de la matrícula en instituciones acreditadas
pct_mujeres	Numérica	Entrada	Derivada de matricula_mujeres	Proporción de la matrícula femenina
log_programas	Numérica	Entrada	Derivada de n_programas	log(1 + programas con matrícula)
log_municipios	Numérica	Entrada	Derivada de n_municipios	log(1 + municipios con matrícula)
region	Categórica	Entrada	dim_geografia.cod_dpto + clasificación regional externa	Región natural del departamento (Andina, Caribe, Pacífica, Orinoquía, Amazonía, Insular)

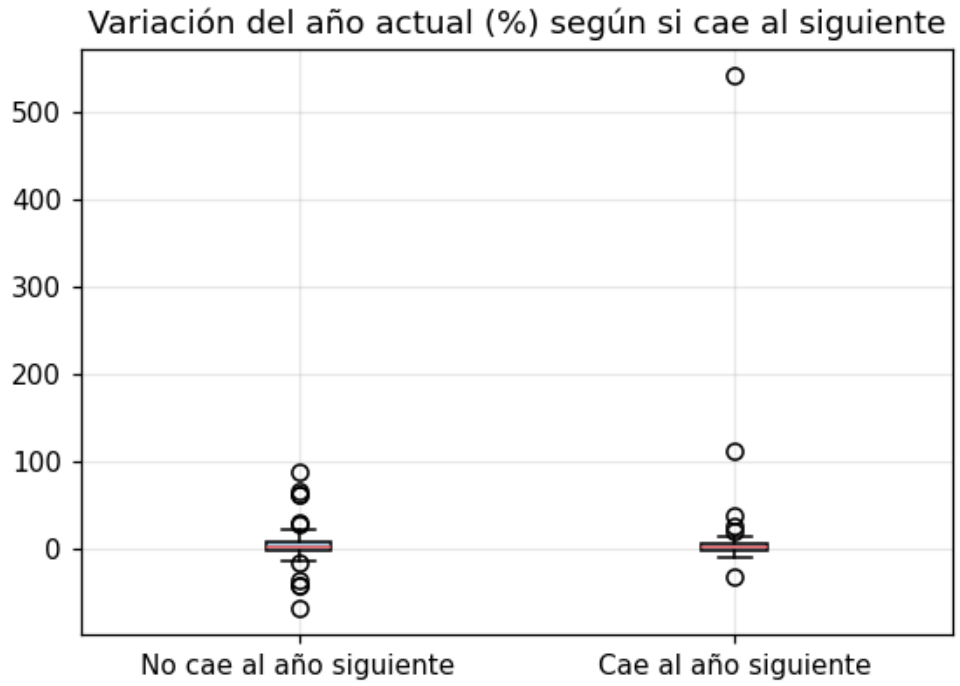
La región no existe en el data warehouse. Se agregó con una clasificación externa por código DANE del departamento (seis regiones naturales), porque la demanda de educación superior puede diferir entre regiones.

2.3 Distribución de la variable objetivo

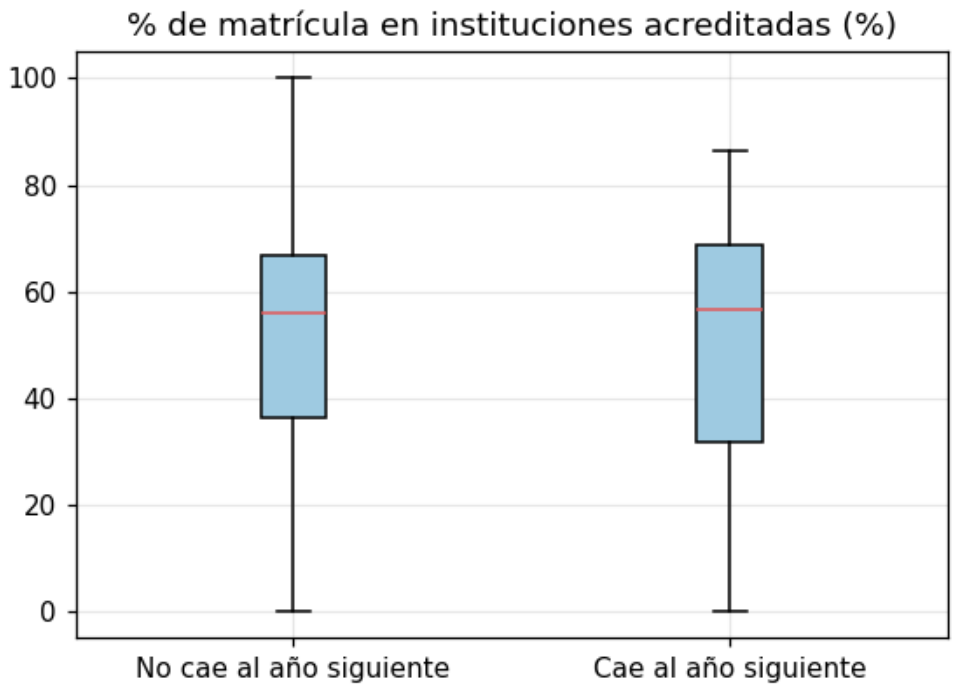


De los 165 registros etiquetados, la matrícula cae al año siguiente en 64 (38,8 %) y no cae en 101 (61,2 %), de modo que las clases están moderadamente desbalanceadas. La variación de la matrícula al año siguiente va de -42,9 % a +541,7 %, con mediana de +1,7 %: en la mitad de los casos la matrícula crece. Hay 20 valores atípicos por la regla del rango intercuartílico, entre ellos el máximo de +541,7 %. La variable objetivo solo usa el signo de esa variación, así que los atípicos no la alteran, pero sí afectan a `var_anual`, que se acota en la sección 3.1.

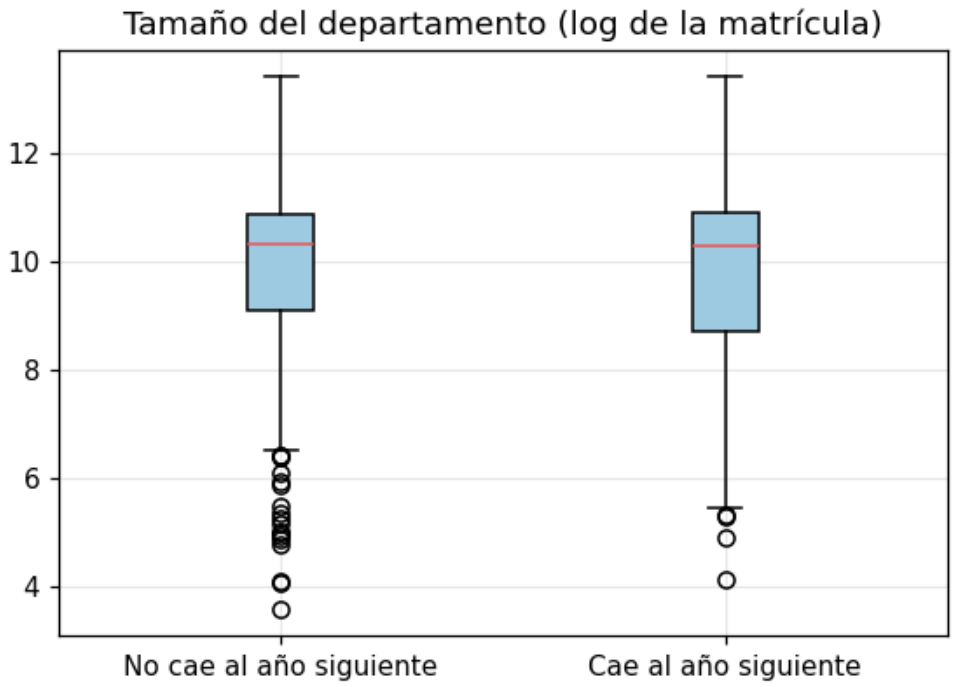
2.4 Análisis exploratorio



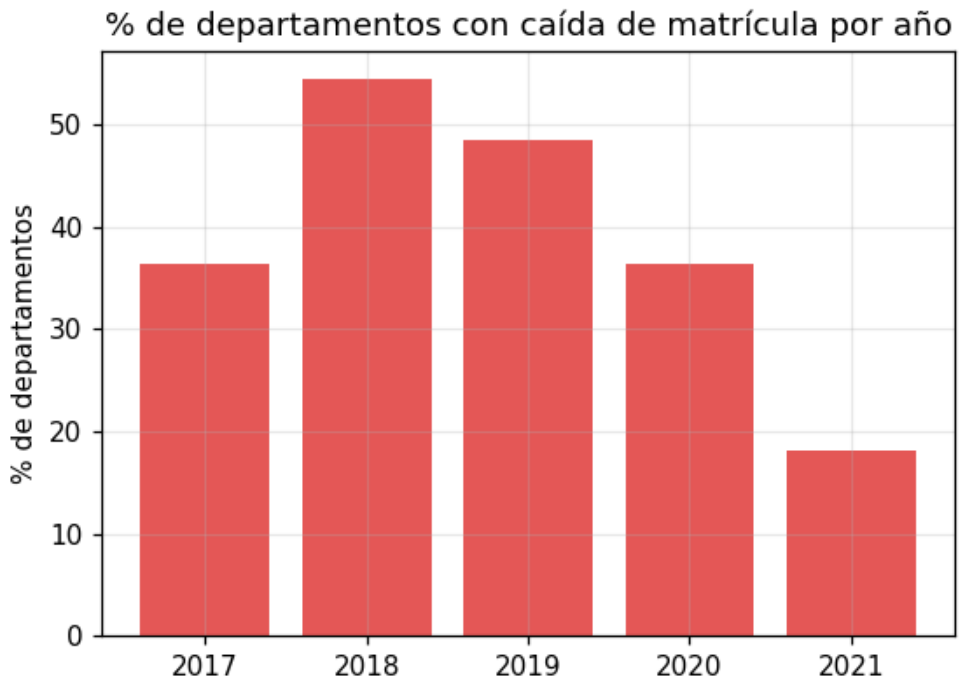
La variación del año actual casi no distingue las clases: la mediana es de 1,6 % en los departamentos que no caen al año siguiente y de 1,7 % en los que caen. El crecimiento reciente, por sí solo, no anticipa la caída.



La proporción de matrícula en instituciones acreditadas tiene medianas muy parecidas (56,1 % en los que no caen y 56,7 % en los que caen). La relación con la caída es débil.



El tamaño del departamento (logaritmo de la matrícula) también es similar: la mediana equivale a unos 30.700 estudiantes en los que no caen y unos 29.200 en los que caen, una diferencia pequeña.



Lo que más cambia es el año: la proporción de departamentos que caen fue de 36,4 % en 2017, 54,5 % en 2018, 48,5 % en 2019, 36,4 % en 2020 y 18,2 % en 2021. El comportamiento depende mucho del año (en 2021 la matrícula se recuperó en casi todo el país), algo que las variables de cada departamento no capturan.

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos estructurales	var_anual, cayo_anio_actual	El primer año de cada departamento no tiene año anterior: esas filas se descartan para entrenar	33
Nulos estructurales	cae_siguiente	El último año no tiene año siguiente: esas filas no se usan para entrenar y sirven para predecir 2022	33
Departamentos incompletos	todas	Se excluyen los departamentos sin matrícula en todos los años (ninguno cumplió esa condición)	0
Atípicos	var_anual	Se acota al rango [-14,9 %; 17,2 %], calculado con la regla del rango intercuartílico solo con el conjunto de entrenamiento	27
Transformación	matricula_s1, n_programas, n_municipios	Logaritmo para reducir la asimetría (Bogotá y Antioquia son mucho mayores que el resto)	231
Codificación categórica	region	One-hot encoding: una columna 0/1 por región (6 columnas), porque las regiones no tienen un orden natural	231

Las columnas del conjunto no tienen valores nulos en el data warehouse; los únicos nulos son los estructurales de la tabla.

3.2 Variables derivadas

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
var_anual	Matrícula del año t sobre la del año t-1, menos 1, para el mismo departamento	La tendencia reciente puede anticipar el siguiente año	Sí
cayo_anio_actual	1 si var_anual es negativa	Distingue departamentos que ya venían cayendo	Sí
log_matricula	Logaritmo natural de la matrícula del año t	Mide el tamaño del departamento sin que Bogotá domine	Sí
pct_acreditada	Matrícula en instituciones acreditadas sobre la matrícula total	La calidad institucional puede relacionarse con la permanencia	Sí, con una salvedad: la acreditación es la vigente al descargar el catálogo y se aplica a todos los años
pct_mujeres	Matrícula de mujeres sobre la matrícula total	Compone la demanda del departamento	Sí
log_programas	Logaritmo de 1 más el número de programas con matrícula	Una oferta amplia puede dar más estabilidad	Sí
log_municipios	Logaritmo de 1 más el número de municipios con matrícula	Mide la cobertura territorial	Sí

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento	99	Años base 2016-2018 (objetivo 2017-2019)
Prueba	66	Años base 2019-2020 (objetivo 2020-2021)

La división es temporal: se entrena con el pasado y se prueba con los años más recientes. En entrenamiento cae el 46,5 % de los casos y en prueba el 27,3 %, porque 2021 fue un año de recuperación. Los 33 registros con año base 2021 se reservan para la predicción de 2022.

4. Modelado

4.1 Algoritmos

Los dos algoritmos se entrenaron con el mismo conjunto de entrenamiento (99 registros) y las mismas 13 variables de entrada: las 7 numéricas de la sección 3.2 y las 6 columnas de región.

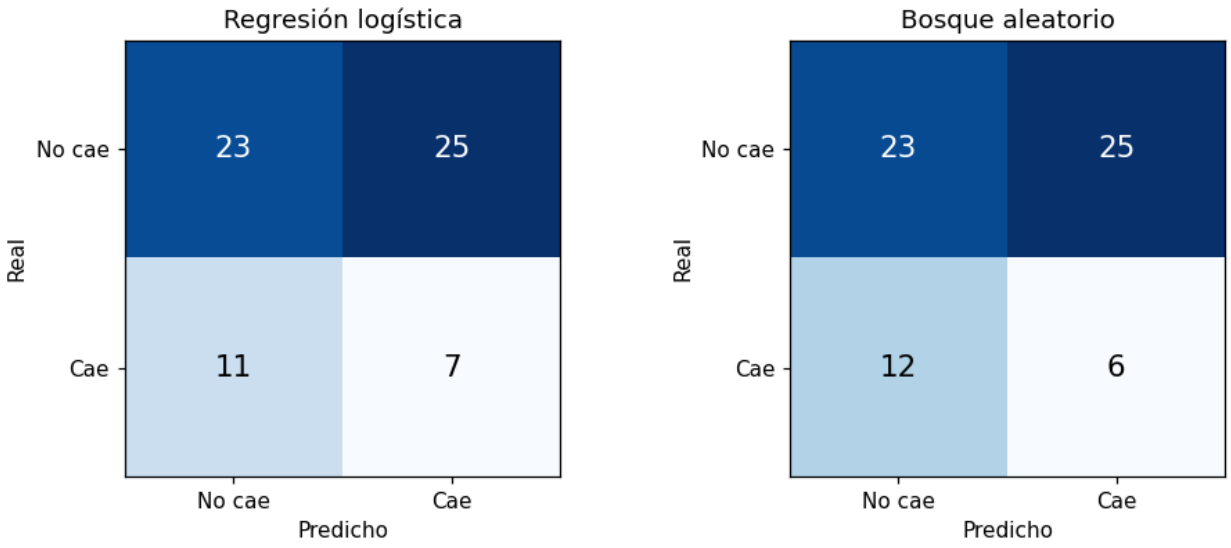
Algoritmo	Por qué se eligió	Parámetros usados
Regresión logística	Modelo base para clasificación binaria; con pocos registros es estable y sus coeficientes se pueden leer y explicar al decisor	C = 1,0; class_weight = «balanced»; max_iter = 1000; random_state = 42; variables estandarizadas
Bosque aleatorio	Captura relaciones no lineales e interacciones entre variables sin necesidad de escalarlas; la profundidad limitada evita sobreajustar con solo 99 registros	n_estimators = 300; max_depth = 4; min_samples_leaf = 3; class_weight = «balanced»; random_state = 42

No se ajustaron hiperparámetros: se usaron valores fijos definidos antes de evaluar para no usar el conjunto de prueba en la selección.

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

Clasificación



Algoritmo	Caídas reales	Detectadas	No detectadas	Falsas alarmas	Exactitud	Precisión	Recall (caídas)	F1
Regresión logística	18	7	11	25	45,5 %	21,9 %	38,9 %	0,28
Bosque aleatorio	18	6	12	25	43,9 %	19,4 %	33,3 %	0,24
Referencia: siempre «no cae»	18	0	18	0	72,7 %	0,0 %	0,0 %	0,00
Referencia: persistencia (si cayó este año, cae el siguiente)	18	9	9	19	57,6 %	32,1 %	50,0 %	0,39

Las dos últimas filas no son algoritmos entrenados: son reglas de referencia para saber si el modelo aporta algo.

Lectura de las matrices. De los 18 departamentos que sí cayeron, la regresión logística detectó 7 y dejó pasar 11; además marcó como caída a 25 de los 48 que no cayeron. El bosque aleatorio detectó 6, dejó pasar 12 y también marcó 25 falsas alarmas. En términos del caso, solo unas 2 de cada 10 alarmas de la regresión logística son reales (precisión de 21,9 %): por cada caída acertada hay unas 3,6 falsas alarmas.

5.2 Comparación y elección

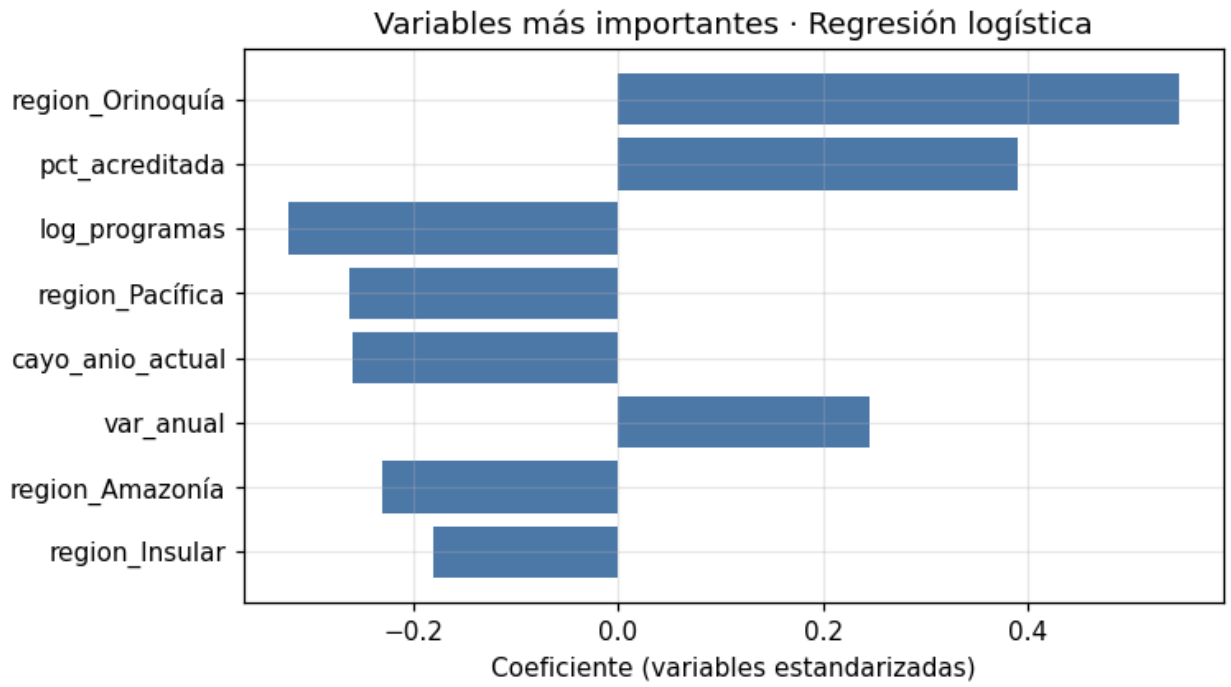
Se elige la **regresión logística**: su F1 en la clase «cae» es de 0,28 frente a 0,24 del bosque aleatorio, y detecta una caída más (7 frente a 6; recall de 38,9 % frente a 33,3 %), con la misma cantidad de falsas alarmas. La diferencia es pequeña (un solo departamento), por lo que ninguno de los dos algoritmos es claramente mejor.

Por año, la regresión logística detectó 4 de las 12 caídas de 2020 (con 9 falsas alarmas) y 3 de las 6 de 2021 (con 16 falsas alarmas):

Año objetivo	Departamentos	Caídas reales	Detectadas	Falsas alarmas	Exactitud
2020	33	12	4	9	48,5 %
2021	33	6	3	16	42,4 %

Ninguno de los dos algoritmos supera la regla de persistencia (F1 de 0,39 y recall de 50 %), lo que muestra que con estos datos el modelo no mejora una regla simple.

5.3 Variables más importantes



Variable	Coeficiente (variables estandarizadas)	Promedio si cae	Promedio si no cae
region_Orinoquía	0,548	0,196	0,057
pct_acreditada	0,390	0,537	0,477

Variable	Coeficiente (variables estandarizadas)	Promedio si cae	Promedio si no cae
log_programas	-0,322	5,124	5,213
region_Pacífica	-0,264	0,065	0,170
cayo_anio_actual	-0,260	0,326	0,434
var_anual	0,246	0,023	0,008
region_Amazonía	-0,231	0,152	0,208
region_Insular	-0,182	0,022	0,038

Los promedios corresponden al conjunto de entrenamiento. Un coeficiente positivo aumenta la probabilidad de caída. Pertenecer a la región Orinoquía es la variable de mayor peso: el 19,6 % de los casos que cayeron son de esa región, frente al 5,7 % de los que no cayeron. Una mayor proporción de matrícula en instituciones acreditadas también se asocia con más riesgo (53,7 % frente a 47,7 %), mientras que una oferta más amplia de programas (`log_programas`) lo reduce. Haber caído ya este año (`cayo_anio_actual`) reduce el riesgo del siguiente, es decir, en entrenamiento los departamentos que cayeron tendieron a recuperarse. Esa relación explica en parte por qué la regla de persistencia, que supone lo contrario, rindió mejor en la prueba. La región Orinoquía reúne pocos departamentos, así que su peso debe tomarse con cautela.

5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
Detectar al menos 6 de cada 10 departamentos que caen (recall mayor o igual a 60 %)	38,9 % (7 de 18)	No
Exactitud mayor que la de predecir siempre «no cae»	45,5 % frente a 72,7 %	No

No se alcanzó el criterio de éxito. La causa principal es el cambio de comportamiento entre entrenamiento y prueba: en entrenamiento caen 46,5 % de los departamentos y en prueba 27,3 %, por el rebote de 2021. Con 99 registros de entrenamiento, el modelo no logra aprender ese cambio.

5.5 Respuesta a la pregunta de negocio

Para 2022 el modelo marca **17 de los 33 departamentos** con caída de matrícula. Esos 17 concentran 1.295.313 estudiantes, el 64,9 % de la matrícula del semestre 1 de 2021. Los de mayor probabilidad de caída son Vichada (73 %), Meta (73 %), Arauca (69 %), Casanare (66 %), Quindío (62 %), Bogotá, D.C. (59 %), Risaralda (58 %) y Santander (55 %). Los cuatro primeros pertenecen a la región Orinoquía, coherente con el peso de esa variable.

La decisión que apoya es dónde concentrar el seguimiento. Como en la prueba solo 2 de cada 10 alarmas fueron ciertas y el modelo detectó 7 de 18 caídas, el viceministro debe usar la lista como una señal para priorizar la revisión de esos departamentos (empezando por los de mayor probabilidad) y no como un pronóstico para asignar o recortar recursos. Para mejorar el modelo hace falta más información por departamento: por ejemplo, ampliar la unidad de análisis a departamento y núcleo del conocimiento, lo que multiplicaría los registros disponibles.

6. Despliegue

6.1 Tabla de predicciones

Las predicciones del modelo elegido están en la tabla `pred_caida_matricula_depto` del data warehouse, con **198 registros**: 99 de entrenamiento, 66 de prueba y 33 de futuro (predicción de 2022). Cada registro es un departamento y un año base. Para los años cuyo resultado ya se conoce, la tabla guarda el valor real junto a la predicción; para 2022, los valores reales quedan vacíos. El script que crea la tabla está en `dw/ddl/09_pred_caida_matricula_depto.sql`, que también crea la vista `vw_dim_departamento` (una fila por departamento) para unir las predicciones con la geografía.

Columna	Tipo	Descripción
sk_tiempo_base	INT	Llave a dim_tiempo: semestre 1 del año en que se hace la predicción
cod_dpto	VARCHAR(5)	Llave a vw_dim_departamento y a dim_geografia.cod_dpto
anio_objetivo	SMALLINT	Año cuya matrícula se predice (año base + 1)
conjunto	VARCHAR(30)	entrenamiento, prueba o futuro
modelo	VARCHAR(40)	Algoritmo elegido (regresión logística)
prob_caida	DECIMAL(6,4)	Probabilidad estimada de que la matrícula caiga
caida_predicha	TINYINT	1 si el modelo predice caída
caida_real	TINYINT	1 si la matrícula cayó; vacío para 2022
matricula_base	INT	Matrícula del semestre 1 del año base
matricula_real	INT	Matrícula del semestre 1 del año objetivo; vacío para 2022
fecha_ejecucion	DATETIME	Fecha y hora de la carga

6.2 Página de predicciones en el tablero

La página «Predicciones» del tablero se titula «Predicción de caída de matrícula por departamento: valores reales y predichos». Muestra, por departamento, la matrícula base, la matrícula real del año siguiente, si cayó realmente, si el modelo predijo caída y la probabilidad estimada, además de tarjetas con las caídas reales, las detectadas y las predichas, y un gráfico con la probabilidad de caída de 2022. Se puede filtrar por departamento, por año objetivo y por conjunto (entrenamiento, prueba o futuro).



Departamento	Año Objetivo	Matrícula Base	Matrícula Real	Estado Real	Predicción	Prob. Caída
SUCRE	2021	26.207	25.095	Cae	No cae	39,82 %
SUCRE	2022	25.095		Sin dato aún	No cae	40,43 %
SANTANDER	2017	108.509	105.851	Cae	No cae	39,13 %
SANTANDER	2018	105.851	107.685	No cae	No cae	38,53 %
SANTANDER	2019	107.685	102.688	Cae	Cae	57,29 %
SANTANDER	2020	102.688	106.153	No cae	No cae	37,26 %
SANTANDER	2021	106.153	110.081	No cae	Cae	57,41 %
SANTANDER	2022	110.081		Sin dato aún	Cae	55,20 %
RISARALDA	2017	42.922	41.687	Cae	Cae	69,54 %
RISARALDA	2018	41.687	41.885	No cae	Cae	50,13 %
RISARALDA	2019	41.885	40.856	Cae	Cae	66,42 %
RISARALDA	2020	40.856	42.232	No cae	Cae	50,31 %
RISARALDA	2021	42.232	42.805	No cae	Cae	66,22 %
RISARALDA	2022	42.805		Sin dato aún	Cae	58,17 %
QUINDÍO	2017	22.022	18.224	Cae	Cae	65,36 %
QUINDÍO	2018	18.224	20.734	No cae	No cae	39,17 %
QUINDÍO	2019	20.734	19.951	Cae	Cae	75,16 %
QUINDÍO	2020	19.951	19.582	Cae	Cae	50,60 %
QUINDÍO	2021	19.582	20.134	No cae	Cae	53,21 %
QUINDÍO	2022	20.134		Sin dato aún	Cae	61,74 %
PUTUMAYO	2017	2.530	2.604	No cae	No cae	20,01 %
PUTUMAYO	2018	2.604	2.693	No cae	No cae	33,16 %
PUTUMAYO	2019	2.693	3.444	No cae	No cae	35,15 %
PUTUMAYO	2020	3.444	4.119	No cae	No cae	45,23 %
PUTUMAYO	2021	4.119	4.878	No cae	No cae	44,56 %
PUTUMAYO	2022	4.878		Sin dato aún	No cae	43,15 %
NORTE DE SANTANDER	2017	62.375	63.316	No cae	Cae	59,24 %
NORTE DE SANTANDER	2018	63.316	61.376	Cae	Cae	56,91 %
NORTE DE SANTANDER	2019	61.376	60.040	Cae	No cae	40,52 %
NORTE DE SANTANDER	2020	60.040	61.144	No cae	No cae	40,64 %
NORTE DE SANTANDER	2021	61.144	63.365	No cae	Cae	56,74 %
NORTE DE SANTANDER	2022	63.365		Sin dato aún	Cae	55,00 %